

# Společná část: 19 - PSI

Náhodná veličina a náhodný vektor. Distribuční funkce, hustota a pravděpodobnostní funkce náhodné veličiny. Střední hodnota a rozptyl náhodné veličiny a jejich odhady. Sdružené charakteristiky náhodného vektoru. Korelace a nezávislost náhodných veličin. Metoda maximální věrohodnosti. Základní principy statistického testování hypotéz. Markovské řetězce, klasifikace stavů.

## 1 Základní pojmy pravděpodobnosti

### 1.1 Laplaceova (klasická) pravděpodobnost

- **Náhodný pokus** má  $n \in \mathbb{N}$  různých, vzájemně se vylučujících výsledků, které jsou stejně možné.
- **Elementární jevy** = výsledky náhodného pokusu
- **Množina všech elementárních jevů:**  $\Omega$
- **Jev** je podmnožina všech elementárních jevů ( $A \subseteq \Omega$ )
- **Pravděpodobnost jevu**  $A$  :

$$P(A) = \frac{|A|}{|\Omega|}$$

- **Jevové pole:** všechny jevy pozorovatelné v náhodném pokusu, zde  $\exp \Omega$  (=množina všech podmnožin množiny  $\Omega$ )

### 1.2 Kolmogorovova pravděpodobnost

- **Elementárních jevů** (=prvků množiny  $\Omega$ ) může být nekonečně mnoho, nemusí být stejně pravděpodobné
- **Jevy** jsou podmnožiny množiny  $\Omega$ , ale ne nutně všechny. Tvoří podmnožinu  $\mathcal{A} \subseteq \exp \Omega$ , která splňuje podmínky  $\sigma$ -algebry (viz. 1.3).
- **Pravděpodobnost** není určena strukturou jevů jako u Laplaceova modelu, je to funkce  $P : \mathcal{A} \rightarrow \langle 0, 1 \rangle$ , splňující podmínky:

$$(P1) \quad P(\mathbf{1}) = 1,$$

$$(P2) \quad P\left(\bigcup_{n \in \mathbb{N}} A_n\right) = \sum_{n \in \mathbb{N}} P(A_n), \text{ pokud jsou množiny (=jevy) } A_n, n \in \mathbb{N}, \text{ po dvou neslučitelné}$$

- **Pravděpodobnostní prostor** je trojice  $(\Omega, \mathcal{A}, P)$ , kde  $\Omega$  je neprázdná množina,  $\mathcal{A}$  je  $\sigma$ -algebra podmnožin množiny  $\Omega$  a  $P$  je pravděpodobnost.

### 1.3 $\sigma$ -algebra

$\sigma$ -algebra je teoretický koncept výběru jistých podmnožin dané množiny, který splňuje pevně definované podmínky. Koncept  $\sigma$ -algebry umožňuje například zavést míru, čehož se dále využívá zejména v matematické analýze k budování pojmu integrál a právě v teorii pravděpodobnosti [wikipedia]. Systém podmnožin  $\mathcal{A}$  nějaké množiny  $\Omega$  musí splňovat podmínky:

1.  $\emptyset \in \mathcal{A}$
2.  $A \in \mathcal{A} \Rightarrow \bar{A} \in \mathcal{A}$  (uzavřenost vůči doplňku)

3.  $(\forall n \in \mathbb{N} : A_n \in \mathcal{A}) \Rightarrow \bigcup_{n \in \mathbb{N}} A_n \in \mathcal{A}$  (uzavřenost vůči sjednocení)

Nejmenší  $\sigma$ -algebra podmnožin  $\mathbb{R}$ , která obsahuje všechny intervaly, se nazývá **Borelova  $\sigma$ -algebra**. Obsahuje všechny intervaly otevřené, uzavřené i polouzavřené, i jejich spočetná sjednocení, a některé další množiny, ale je menší než  $\exp \mathbb{R}$ . Její prvky nazýváme borelovské množiny.

## 2 Náhodná veličina a náhodný vektor

### 2.1 Náhodná veličina

Je na pravděpodobnostním prostoru  $(\Omega, \mathcal{A}, P)$  měřitelná funkce  $X : \Omega \rightarrow \mathbb{R}$  (přiřazuje každému jevu jevového pole reálné číslo [wikipedia]).

Náhodné veličiny lze rozdělit na nespojitě (diskrétní) a spojitě. Diskrétní veličiny mohou nabývat pouze spočetného počtu hodnot (konečného i nekonečného), zatímco spojitě veličiny nabývají hodnoty z nějakého intervalu (konečného nebo nekonečného) [wikipedia].

**Příklad:** Havárie aut označíme cenou škody a můžeme se ptát, jak je pravděpodobné, že havárie dosáhne určité škody.


Pro každý interval  $I$  platí

$$X^{-1}(I) = \{\omega \in \Omega \mid X(\omega) \in I\} \in \mathcal{A}$$

Popisuje ji **Rozdělení pravděpodobnosti** náhodné veličiny  $X$ :

$$P_X(I) = P[X \in I] = P(\{\omega \in \Omega \mid X(\omega) \in I\})$$

to je funkce, která udává pravděpodobnost toho, že náhodná veličina nabyde určité hodnoty.





Místo pravděpodobnostní funkce, můžeme použít úspornější **Distribuční funkci** ( $F_X$ ), která se omezuje na intervaly tvaru  $I = (-\infty, t], t \in \mathbb{R}$

$$P[X \in (-\infty, t]] = P[X \leq t] = P_X((-\infty, t]) = F_X(t)$$

Různými kombinacemi distribuční funkce ( $F_X : \mathbb{R} \rightarrow \langle 0, 1 \rangle$ ) můžeme plně nahradit pravděpodobnostní funkci.

**Vlastnosti distribuční funkce:**

- neklesající
- zprava spojitá
- $\lim_{t \rightarrow -\infty} F_X(t) = 0, \lim_{t \rightarrow \infty} F_X(t) = 1$



Distribuční funkce pro absolutně spojitou veličinu:

$$F_X(t) = \int_{-\infty}^t f_X(u) du,$$

kde  $f_X$  je tzv. **hustota náhodné veličiny**. Je to nezáporná funkce ( $f_X : \mathbb{R} \rightarrow \langle 0, \infty \rangle$ ) a splňuje  $\int_{-\infty}^{\infty} f_X(u) du = 1$ . Náhodné veličiny  $X_1, \dots, X_n$  jsou **nezávislé**, pokud pro všechny intervaly  $I_1, \dots, I_n$  jsou jevy  $X_1 \in I_1, \dots, X_n \in I_n$  nezávislé, tj.

$$P[X_1 \in I_1, \dots, X_n \in I_n] = \prod_{i=1}^n P[X_i \in I_i]$$

## 2.2 Náhodný vektor (n-rozměrná náhodná veličina)

Je na pravděpodobnostním prostoru  $(\Omega, \mathcal{A}, P)$  měřitelná funkce  $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ . Používáme ho v případech, kdy je k popisu výsledku náhodného pokusu nutné použít více čísel [wikipedia].

**Příklad:** Chceme popsat vztah např. mezi výškou a váhou osob. K tomu potřebujeme více informací než jen popis jednotlivých náhodných veličin.

Pro každý  $n$ -rozměrný interval  $I$  platí

$$\mathbf{X}^{-1}(I) = \{\omega \in \Omega \mid \mathbf{X}(\omega) \in I\} \in \mathcal{A}$$

Lze psát

$$\mathbf{X}(\omega) = (X_1(\omega), \dots, X_n(\omega)),$$

kde zobrazení  $X_k : \Omega \rightarrow \mathbb{R}, k = 1, \dots, n$  jsou náhodné veličiny.

Náhodný vektor lze považovat za vektor náhodných veličin  $\mathbf{X} = (X_1, \dots, X_n)$ .

Je popsán **Sdruženým rozdělením pravděpodobnosti**:

$$P_{\mathbf{X}}(I_1 \times \dots \times I_n) = P[X_1 \in I_1, \dots, X_n \in I_n] = P(\{\omega \in \Omega \mid X_1(\omega) \in I_1, \dots, X_n(\omega) \in I_n\}),$$

kde  $I_1, \dots, I_n$  jsou intervaly v  $\mathbb{R}$ . Z toho vyplývá pravděpodobnost pro libovolnou borelovskou množinu  $I$  v  $\mathbb{R}^n$

$$P_{\mathbf{X}}(I) = P[\mathbf{X} \in I] = P(\{\omega \in \Omega \mid \mathbf{X}(\omega) \in I\})$$

Opět můžeme použít úspornější **Sdruženou distribuční funkci** ( $F_{\mathbf{X}}$ )

$$P[X_1 \in (-\infty, t_1], \dots, X_n \in (-\infty, t_n]] = P[X_1 \leq t_1, \dots, X_n \leq t_n] = P_{\mathbf{X}}((-\infty, t_1] \times \dots \times (-\infty, t_n]) = F_{\mathbf{X}}(t_1, \dots, t_n)$$

**Vlastnosti distribuční funkce:**

- neklesající (ve všech proměnných)
- zprava spojitá (ve všech proměnných)
- $\lim_{t_1 \rightarrow \infty, \dots, t_n \rightarrow \infty} F_{\mathbf{X}}(t_1, \dots, t_n) = 1$
- $\lim_{t_1 \rightarrow -\infty, \dots, t_n \rightarrow -\infty} F_{\mathbf{X}}(t_1, \dots, t_n) = 0$

## 2.3 Obecné náhodné veličiny

Náhodné veličiny nemusí být reprezentovány pouze reálnými čísly, ale třeba i čísly komplexními. V některých případech se používají i jiné než numerické hodnoty, například "rub", "líc", "kámen", "papír" atp.

# 3 Základní charakteristiky náhodných veličin a náhodných vektorů

## 3.1 Střední hodnota

Značení  $E$  nebo  $\mu$ . Jedná se o tzv. charakteristiku polohy (angl. measures of central tendency)

### 3.1.1 Střední hodnota náhodné veličiny

Je definována zvlášť pro:

- **diskrétní** náhodnou veličinu  $U$  s oborem hodnot  $\mathbb{R}$ :

$$EU = \mu_U = \sum_{t \in \mathbb{R}} t \cdot p_U(t)$$

- **spojitou** náhodnou veličinu  $V$ :

$$EV = \mu_V = \int_{-\infty}^{\infty} t \cdot f_V(t) dt$$

### 3.1.2 Střední hodnota náhodného vektoru

$$EX = (EX_1, \dots, EX_n)$$

## 3.2 Rozptyl (disperze)

Značení  $\sigma^2$ ,  $D$ ,  $var$ . Jedná se o charakteristiku variability (angl. measures of central tendency).

### 3.2.1 Rozptyl náhodné veličiny

Je to vlastně střední hodnota kvadrátu odchylky od střední hodnoty.

$$DX = E\left((X - EX)^2\right) = E(X^2) - (EX)^2$$

### 3.2.2 Rozptyl náhodného vektoru

$$DX = (DX_1, \dots, DX_n)$$

## 3.3 Další číselné charakteristiky náhodného vektoru

Pro jednorozměrné náhodné veličiny střední hodnota a rozptyl dávají **dostatečnou** informaci pro výpočet rozptylu jeho lineárních funkcí (lineární kombinace různých náhodných veličin):

$$E(X + Y) = EX + EY$$

$$E(X - Y) = EX - EY$$

$$D(X + Y) = DX + DY$$

$$D(X - Y) = DX + DY$$

Pro náhodný vektor to ale nestačí, a proto zavádíme další charakteristiky:

$$E(X + Y) = EX + EY$$

$$D(X + Y) = DX + DY + 2cov(X, Y),$$

kde  $cov(X, Y)$  je kovariance náhodných veličin  $X, Y$ .

### 3.3.1 Kovariance a korelace

**Kovariance** určuje míru statistické závislosti mezi náhodnými veličinami. Je definována jako střední hodnota součinu odchylek obou náhodných veličin  $X, Y$  od jejich středních hodnot (druhý vzorec není tak srozumitelný, ale je jednodušší pro výpočet)

$$\text{cov}(X, Y) = E((X - EX)(Y - EY)) = E(XY) - EXEY$$

Vlastnosti kovariance:

$$\text{cov}(X, X) = DX,$$

$$\text{cov}(Y, X) = \text{cov}(X, Y)$$

$$\text{cov}(aX + b, cY + d) = ac \text{cov}(X, Y)$$

$$\text{cov}(X, Y) = 0 - \text{pro nezávislé veličiny}$$

Při výpočtech je místo kovariance výhodnější používat **korelaci** (což je kovariance pro normované náhodné veličiny)

$$\varrho(X, Y) = \text{cov}(\text{norm } X, \text{norm } Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = E(\text{norm } X \cdot \text{norm } Y)$$

Korelace nabývá hodnot  $\langle -1, 1 \rangle$ , pro  $\varrho = 1$  je mezi  $X, Y$  přímá lineární závislost, pro  $\varrho = -1$  nepřímá lineární závislost. Pro  $\varrho = 0$  říkáme, že jsou veličiny **nekorelované**. Zároveň to znamená, že jsou lineárně nezávislé, nikoliv obecně nezávislé (je to nutná podmínka pro obecnou nezávislost, ale nikoliv postačující).

Pro náhodný vektor  $\mathbf{X} = (X_1, \dots, X_n)$  definujeme **kovariační matici**:

$$\Sigma_{\mathbf{X}} = \begin{bmatrix} \text{cov}(X_1, X_1) & \text{cov}(X_1, X_2) & \dots & \text{cov}(X_1, X_n) \\ \text{cov}(X_2, X_1) & \text{cov}(X_2, X_2) & \dots & \text{cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_n, X_1) & \text{cov}(X_n, X_2) & \dots & \text{cov}(X_n, X_n) \end{bmatrix} = \begin{bmatrix} DX_1 & \text{cov}(X_1, X_2) & \dots & \text{cov}(X_1, X_n) \\ \text{cov}(X_2, X_1) & DX_2 & \dots & \text{cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_n, X_1) & \text{cov}(X_n, X_2) & \dots & DX_n \end{bmatrix}$$

a **korelační matici**:

$$\varrho_{\mathbf{X}} = \begin{bmatrix} 1 & \varrho(X_1, X_2) & \dots & \varrho(X_1, X_n) \\ \varrho(X_2, X_1) & 1 & \dots & \varrho(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \varrho(X_n, X_1) & \varrho(X_n, X_2) & \dots & 1 \end{bmatrix}$$